Entrega 2: Descripción del Dataset y Origen

Proyecto: Predicción de episodios de hipoglucemia mediante Aprendizaje Automático

Dataset: CGMacros

Entorno de trabajo: Anaconda – Jupyter Notebook – Python

Fecha: 26 de octubre de 2026

1. Origen del dataset y lugar del estudio

El dataset CGMacros procede de una investigación científica sobre nutrición personalizada, monitoreo continuo de glucosa y actividad física.

El estudio se desarrolló en el **Sansum Diabetes Research Institute (SDRI), ubicado en Santa Bárbara, California, Estados Unidos**, donde fueron reclutados los participantes.

En la investigación participaron profesionales vinculados a diferentes instituciones, entre ellas Texas A&M University y Sansum Diabetes Research Institute.

Los participantes fueron reclutados entre 2021 y 2024.

Los resultados se publicaron el 25 de septiembre de 2025 en la revista científica *Scientific Data*, bajo el título:

CGMacros: a pilot scientific dataset for personalized nutrition and diet monitoring.

2. Participantes del estudio

La investigación incluyó 45 participantes adultos, de entre 18 y 69 años, clasificados según sus valores de hemoglobina glucosilada (HbA1c):

- 15 participantes sin diabetes.
- 16 participantes con prediabetes.
- 14 participantes clasificados con diabetes tipo 2.

Para el presente proyecto se seleccionaron los **14 participantes con diabetes tipo 2**, utilizando como criterio un valor de HbA1c superior al 6,4 %.

Esta selección se realizó mediante Python y la biblioteca Pandas, utilizando la información clínica disponible en el archivo bio.csv.

3. Procedimiento de recopilación de datos

Los participantes fueron estudiados durante aproximadamente 10 días consecutivos, mientras realizaban sus actividades cotidianas.

Para recopilar la información se utilizaron diferentes dispositivos y herramientas:

- **Abbott FreeStyle Libre Pro:** monitoreo continuo de glucosa con mediciones cada 15 minutos.
- **Dexcom G6 Pro:** monitoreo continuo de glucosa con mediciones cada 5 minutos.
- **Fitbit Sense:** registro de actividad física, frecuencia cardíaca y gasto energético.
- **MyFitnessPal:** registro de comidas y composición nutricional.
- **WhatsApp:** fotografías de los alimentos consumidos.
- **Análisis de laboratorio:** determinaciones de HbA1c, glucosa, insulina, colesterol y triglicéridos, entre otras variables.

Los investigadores realizaron un procesamiento de los registros para integrar la información de los distintos dispositivos.

Las mediciones de glucosa fueron interpoladas linealmente para generar registros con intervalos uniformes de un minuto.

Además, las fechas originales fueron desplazadas para preservar la privacidad de los participantes.

4. Descripción general del dataset utilizado

El dataset CGMacros contiene registros temporales de glucosa, actividad física, alimentación y características clínicas.

Para nuestro proyecto se seleccionaron 14 archivos CSV, correspondientes a los participantes con diabetes tipo 2.

En conjunto, estos archivos contienen **218.535 registros**, distribuidos de la siguiente manera:

Participante	Registros	Columnas
CGMacros-003	14.565	15
CGMacros-005	14.460	15
CGMacros-012	14.655	14
CGMacros-014	17.250	14
CGMacros-028	18.735	13
CGMacros-030	15.465	14
CGMacros-035	14.400	14
CGMacros-036	17.115	15
CGMacros-038	14.505	14
CGMacros-039	17.205	14
CGMacros-042	14.520	14
CGMacros-046	14.655	14
CGMacros-047	15.690	14
CGMacros-049	15.315	15
Total	**218.535**	

La cantidad de columnas varía entre 13 y 15 según el participante.

Cada registro representa una observación temporal de una persona. Por lo tanto, los 218.535 registros corresponden a mediciones repetidas de 14 participantes y no a 218.535 pacientes diferentes.

5. Variables y tipos de datos

Los archivos contienen variables relacionadas con el monitoreo de glucosa, la actividad física y la alimentación.

Como ejemplo, se describen las 15 columnas identificadas en el archivo CGMacros-003.

Variable	Descripción	Tipo de dato
Unnamed: 0	Índice del archivo	Entero
Timestamp	Fecha y hora	Fecha/hora
Libre GL	Glucosa registrada por sensor Libre	Decimal
Dexcom GL	Glucosa registrada por sensor Dexcom	Decimal
HR	Frecuencia cardíaca	Decimal
Calories (Activity)	Calorías de actividad física	Decimal
METs	Equivalentes metabólicos	Entero
Meal Type	Tipo de comida	Texto
Calories	Calorías alimentarias	Decimal
Carbs	Carbohidratos	Decimal
Protein	Proteínas	Decimal
Fat	Grasas	Decimal
Fiber	Fibra alimentaria	Decimal
Amount Consumed	Cantidad consumida	Decimal
Image path	Ruta de imagen de comida	Texto

Las variables presentan diferentes tipos de datos: numéricos, categóricos y temporales.

También existen valores faltantes en algunas columnas, debido a que no todas las variables presentan información en cada registro.

Por ejemplo, en el archivo CGMacros-003, que contiene 14.565 registros, se identificaron:

- Libre GL: 14.565 valores disponibles.
- Dexcom GL: 14.260 valores disponibles.
- HR: 14.478 valores disponibles.
- Meal Type: 35 valores disponibles.

Estas diferencias deberán considerarse durante las etapas posteriores de preparación de datos y entrenamiento del modelo.

6. Información clínica y demográfica

Además de los archivos individuales, se utiliza el archivo bio.csv, que contiene 24 columnas con información clínica y demográfica.

Entre las principales variables se encuentran:

- Edad y sexo.
- Peso, altura e índice de masa corporal (IMC).
- Hemoglobina glucosilada (HbA1c).
- Glucemia en ayunas.
- Insulina.
- Colesterol y triglicéridos.
- Otras variables del perfil lipídico.

La variable HbA1c permitió seleccionar los 14 participantes incluidos en el proyecto.

7. Aplicación del dataset al proyecto

El objetivo es desarrollar un modelo de Aprendizaje Automático que permita predecir episodios de hipoglucemia utilizando información previa de glucosa y actividad física.

Para este proyecto se define operativamente un episodio de hipoglucemia como un período durante el cual la glucosa permanece por debajo de 70 mg/dL durante al menos 15 minutos.

Las principales variables de interés son:

- Glucosa registrada mediante monitoreo continuo.
- Actividad física.
- Equivalentes metabólicos (METs).
- Información temporal de las mediciones.

Aunque el dataset contiene frecuencia cardíaca y variables alimentarias, estas no forman parte de las variables principales seleccionadas para el modelo.

El análisis permitirá estudiar la relación entre la actividad física y los episodios de hipoglucemia, para posteriormente desarrollar un modelo de clasificación.

8. Procesamiento inicial de los datos

El trabajo se realizó utilizando Anaconda, Jupyter Notebook, Python y la biblioteca Pandas.

El procedimiento inicial consistió en:

1. Cargar el archivo bio.csv.
2. Identificar a los participantes con HbA1c superior al 6,4 %.
3. Seleccionar los 14 participantes correspondientes.
4. Localizar y cargar sus archivos CSV individuales.
5. Examinar la cantidad de registros, columnas y tipos de datos.
6. Iniciar el análisis de episodios de hipoglucemia.

Este procedimiento se encuentra documentado en la notebook del proyecto.

9. Organización del repositorio GitHub

Los archivos utilizados se encuentran disponibles en el repositorio:

Parcial-de-Aprendizaje-Automatico

https://github.com/DanielRojas-creator/Parcial-de-Aprendizaje-Automatico

La organización incluye:

Carpeta data:

- Subcarpeta CGMacros_14_CSV_GitHub, con los 14 archivos CSV seleccionados.
- Archivo bio.csv.
- Archivo README.md.

Carpeta notebooks:

- Archivo Hipoglucemia_ejercicio_diabetes.ipynb.

La notebook contiene la selección de participantes, carga de datos y análisis inicial de los registros.

10. Fuentes científicas

Dataset original:

CGMacros, versión 1.0.0. PhysioNet. Publicado el 28 de enero de 2025.

https://physionet.org/content/cgmacros/1.0.0/

DOI: https://doi.org/10.13026/3z8q-x658

Artículo científico:

Das, A., Kerr, D., Glantz, N., Bevier, W., Santiago, R., Gutierrez-Osuna, R. y Mortazavi, B. J. (2025).

CGMacros: a pilot scientific dataset for personalized nutrition and diet monitoring.

Scientific Data, 12, artículo 1557.

https://doi.org/10.1038/s41597-025-05851-7

11. Conclusión

El dataset CGMacros proporciona información clínica y temporal que permite estudiar la relación entre la glucosa, la actividad física y la aparición de episodios de hipoglucemia.

Para este proyecto se seleccionaron 14 participantes con diabetes tipo 2, cuyos archivos contienen un total de 218.535 registros.

La disponibilidad de mediciones continuas de glucosa y datos de actividad física permite abordar el problema mediante técnicas de Aprendizaje Automático.

Los archivos y la notebook se encuentran organizados en GitHub, lo que facilita la documentación, el acceso a los datos y la reproducibilidad del trabajo.